

DM R & Python

Réponses aux questions + code

1) Choix des variables :


```
Variables_quantitatives <- c("age", "edu", "surv2md1", "das2d3pc", "wblc1",  
"pot1", "temp1", "pafi1", "alb1", "hema1", "bili1", "crea1", "wtkilo1", "ph1",  
"paco21")
```

```
Variables_qualitatives_binaires <- c("sex", "death", "dth30", "card", "dnr1")
```

2) Création du tableau :

	No RHC	RHC	SMD
n	3551	2184	
age (mean (SD))	61.76 (17.29)	60.75 (15.63)	0.061
edu (mean (SD))	11.57 (3.13)	11.86 (3.16)	0.091
surv2md1 (mean (SD))	0.61 (0.19)	0.57 (0.20)	0.198
das2d3pc (mean (SD))	20.37 (5.48)	20.70 (5.03)	0.063
wblc1 (mean (SD))	15.26 (11.41)	16.27 (12.55)	0.084
pot1 (mean (SD))	4.08 (1.04)	4.05 (1.01)	0.027
temp1 (mean (SD))	37.63 (1.74)	37.59 (1.83)	0.021
pafi1 (mean (SD))	240.63 (116.66)	192.43 (105.54)	0.433
alb1 (mean (SD))	3.16 (0.67)	2.98 (0.93)	0.230
hema1 (mean (SD))	32.70 (8.79)	30.51 (7.42)	0.269
bili1 (mean (SD))	2.00 (4.43)	2.71 (5.33)	0.145
crea1 (mean (SD))	1.92 (2.03)	2.47 (2.05)	0.270
wtkilo1 (mean (SD))	65.04 (29.50)	72.36 (27.73)	0.256
ph1 (mean (SD))	7.39 (0.11)	7.38 (0.11)	0.120
paco21 (mean (SD))	39.95 (14.24)	36.79 (10.97)	0.249
sex = Male (%)	1914 (53.9)	1278 (58.5)	0.093
death = Yes (%)	2236 (63.0)	1486 (68.0)	0.107
dth30 = Yes (%)	1088 (30.6)	830 (38.0)	0.156
card = Yes (%)	1007 (28.4)	924 (42.3)	0.295
dnr1 = Yes (%)	499 (14.1)	155 (7.1)	0.228


3) Représentation graphique pour représenter les SMD des différentes variables, triés du plus grand au plus petit :



4) Proposer un code permettant de randomiser le traitement RHC chez ces patients :

```
set.seed(123)
rawData$RHC_randomized <- sample(rawData$swang1, nrow(rawData),
replace = FALSE)
table(rawData$RHC_randomized)
head(rawData)
```

5) Recalculer les SMD pour les données après avoir randomisé le traitement et ajouter les valeurs au graphe :



6) L'utilisation des SMD dans les études observationnelles :

Permet **d'identifier les déséquilibres potentiels** entre les groupes de traitement car dans les études observationnelles, les patients ne sont pas assignés au hasard, ce qui peut entraîner des différences importantes entre les groupes, il permet de quantifier ces déséquilibres, par exemple dans le 2eme graphe certaines covariables, comme crea1 ou pafi1, sont fortement déséquilibrées dans les groupes initiaux.

Cela peut biaiser l'estimation des effets de traitement si ces déséquilibres ne sont pas corrigés.

La Randomisation : La randomisation réduit les SMD, équilibrant les caractéristiques entre les groupes, car la randomisation répartit aléatoirement les caractéristiques des patients entre les groupes.

En conclusion, Les SMD sont un outil essentiel pour évaluer et visualiser l'équilibre des covariables dans les études observationnelles, la randomisation permet de corriger les déséquilibres initiaux pour limiter le biais des estimations causé par des déséquilibres dans les caractéristiques des patients.

CODE :

```
#Charger les données
urlPath <- "https://hbiostat.org/data/repo/rhc.csv"
rawData <- read.csv(urlPath, header = TRUE)
str(rawData)

#Conversion
rawData$sex <- as.factor(rawData$sex)
rawData$death <- as.factor(rawData$death)
rawData$dth30 <- as.factor(rawData$dth30)
rawData$card <- as.factor(rawData$card)
rawData$dnr1 <- as.factor(rawData$dnr1)

#1#Choix des variables:
variables_quantitatives <- c("age", "edu", "surv2md1", "das2d3pc", "wblc1", "pot1",
                             "temp1", "pafi1", "alb1", "hema1", "bili1", "crea1",
                             "wtkilo1", "ph1", "paco21")
variables_qualitatives_binaires <- c("sex", "death", "dth30", "card", "dnr1")

#2#Création du tableau:
library(tableone)
group <- "swang1"
table <- CreateTableOne(vars = c(variables_quantitatives,
                                  variables_qualitatives_binaires),
                        strata = group, data = rawData, test = FALSE)

table_with_smd <- print(table, smd = TRUE)
print(table_with_smd)

#3#Création graphique:
smd_table <- as.data.frame(print(table, smd = TRUE))
smd_table$Variable <- rownames(smd_table)
rownames(smd_table) <- NULL
smd_data <- smd_table[, c("Variable", "SMD")]
```

```
smd_data$SMD <- trimws(smd_data$SMD)
smd_data$SMD[smd_data$SMD == ""] <- NA
smd_data$SMD <- as.numeric(smd_data$SMD)
smd_data <- na.omit(smd_data)
```

```
# Trier les variables par SMD décroissant
smd_data <- smd_data[order(-smd_data$SMD), ]
```

```
library(ggplot2)
ggplot(smd_data, aes(x = reorder(Variable, SMD), y = SMD)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() + # Inverser les axes pour un barplot horizontal
  theme_minimal() +
  labs(title = "SMD des variables triées",
       x = "Variable",
       y = "Standardized Mean Difference (SMD)")
```

```
str(smd_data)
```

```
#4#Proposer un code pour randomiser RHC
set.seed(123)
rawData$RHC_randomized <- sample(rawData$swang1, nrow(rawData), replace =
FALSE)
table(rawData$RHC_randomized)
head(rawData)
```

```
#5#Recalculer les SMD:
table_randomized <- CreateTableOne(vars = c(variables_quantitatives,
variables_qualitatives_binaires),
strata = "RHC_randomized", data = rawData, test = FALSE)
```

```
smd_table_randomized <- as.data.frame(print(table_randomized, smd = TRUE))
smd_table_randomized$Variable <- rownames(smd_table_randomized)
rownames(smd_table_randomized) <- NULL
smd_data_randomized <- smd_table_randomized[, c("Variable", "SMD")]
smd_data_randomized$SMD <- as.numeric(trimws(smd_data_randomized$SMD))
smd_data_randomized <- na.omit(smd_data_randomized)
```

```
smd_data_observed <- smd_data
smd_combined <- merge(smd_data_observed, smd_data_randomized, by =
"Variable", suffixes = c("_observed", "_randomized"))
```

```
# Restructuration des données pour le graphique
library(tidyr)
smd_combined_long <- smd_combined %>%
  pivot_longer(cols = c(SMD_observed, SMD_randomized), names_to = "Groupe",
values_to = "SMD")
```

```

#Création du graphique avec geom_jitter :
library(ggplot2)
ggplot(smd_combined_long, aes(x = reorder(Variable, -SMD), y = SMD, color =
Groupe)) +
  geom_jitter(width = 0.2, size = 3, alpha = 0.7) +
  coord_flip() +
  theme_minimal() +
  scale_color_manual(values = c("SMD_observed" = "skyblue", "SMD_randomized" =
"green"),
    labels = c("Observé", "Randomisé")) +
  labs(
    title = "Comparaison des SMD entre groupes observé et randomisé",
    x = "Variable",
    y = "Différence Moyenne Standardisée (SMD)",
    color = "Groupe"
  )

```