

Université de Strasbourg
Faculté de chirurgie dentaire
Master 1 – Intelligence en Données de Santé

Rapport de stage

Application de la méthode IPTW pour l'analyse de données observationnelles

Réalisé par :

Halliche Nesrine

Encadré par :

Julien Godet

Structure d'accueil :

Laboratoire ICube (UMR 7357 – CNRS, Université de Strasbourg)

Période de stage :

17/03/2025-16/05/2025

Année universitaire :

2024 – 2025

Application de la méthode IPTW pour l'analyse de données observationnelles.

1. Objectif :

Cette analyse vise à estimer l'effet causal marginal du traitement antibiotique (A) sur la mortalité intrahospitalière (Y) à l'aide de la méthode de pondération par l'Inverse Probability of Treatment Weighting (IPTW). Cette approche permet de simuler un contexte d'essai randomisé en équilibrant les covariables entre les groupes traités et non traités.

2. Description des données

Variables clés :

- **A (Traitement)** : administration d'antibiotiques
- **Y (Outcome)** : mortalité intrahospitalière (binaire)
- Un résumé descriptif des variables a été réalisé à l'aide des packages summarytools (dfSummary) et skimr (skim), permettant d'avoir une vue d'ensemble des distributions, types de données et valeurs manquantes.
- Un tableau a été généré pour lister les variables contenant des valeurs manquantes (NA).
- Les valeurs manquantes ont été identifiées et imputées par la **médiane** pour les variables continues.
- Les variables qualitatives ont été traitées en tant que facteurs.

```
# Variables explicatives |
vars <- c(
  "age", "sexe", "diabete", "hta", "tabacActif", "obesiteSurpoids",
  "atcdCardioVasculaire1", "atcdRespiratoires", "scoreKnaus", "glasgowIoa",
  "sous02Ioa", "fc", "tAs", "tAd", "temperature",
  "moarriueUrgences", "delaiDepuisApparitionPremierSymptome",
  "consultPrealablePassageSu", "presentationCliniqueUrgences",
  "creatinineAdmission", "dfg", "natremie", "crpAdmission", "leucocytesTotadmission"
)
df_clean <- df %>%
  mutate(across(all_of(vars), ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))
```

3. Analyse brute (non ajustées)

Une régression logistique simple ($\text{glm}(Y \sim A)$) a d'abord été réalisée sans ajustement. Cette modélisation permet d'estimer l'**odds ratio (OR)**, c'est-à-dire la probabilité de décès chez les patients ayant reçu des antibiotiques, comparée à ceux n'en ayant pas reçu.

Résultats :

```
> # 4. Affichage propre
> print(effet_brut_A)
# A tibble: 1 x 4
  variable      OR `IC 95%`      `p-value`
  <chr>      <dbl> <chr>      <chr>
1 A (antibio) 4.12 [2.39 ; 7.44] < 0.001
```

Interprétation :

L'odds ratio brut est de 4.12, ce qui signifie que la cote de décès chez les patients ayant reçu des antibiotiques est 4,12 fois plus élevée que celle observée chez les patients n'en ayant pas reçu. Cette estimation suggère une association positive entre l'administration d'antibiotiques et la mortalité.

Cependant, cette interprétation doit être nuancée. Il ne s'agit pas d'un risque relatif mais bien d'un rapport de cotes (odds ratio). Assimiler un OR à un facteur multiplicatif du risque peut être approximatif, notamment lorsque la prévalence de l'événement n'est pas faible, ce qui semble être le cas ici.


Enfin, cette estimation non ajustée est susceptible d'être biaisée par des facteurs de confusion. En particulier, les patients les plus graves étant plus susceptibles de recevoir des antibiotiques, il est probable que l'OR reflète en partie cette différence de gravité plutôt qu'un effet causal du traitement. D'où la nécessité d'appliquer une méthode d'ajustement comme l'IPTW pour corriger ces biais.

4. Estimation des scores de propension et calcul des poids IPTW

Un modèle de **score de propension (PS)** a été ajusté à l'aide de la fonction `weightit()` avec la méthode "ps" (régression logistique) et l'estimand "ATE" (Average Treatment Effect). Les poids ont ensuite été extraits et ajoutés au jeu de données.

5. Équilibre des covariables

Un tableau de balance a été généré avec `bal.tab()` du package `cobalt`. Le graphique ci-dessous (love plot) illustre les déséquilibres avant (en rouge) et après (en bleu) pondération :



- **Avant pondération** : de nombreuses variables présentaient un déséquilibre > 0.1 .
- **Après pondération** : 24 variables sont équilibrées, 2 variables demeurent déséquilibrées :
 - `glasgowloa` : Diff.Adj = 0.2913

- crpAdmission : Diff.Adj = 0.1188


Globalement, l'équilibrage est satisfaisant.

6. Estimation de l'effet du traitement antibiotique

Un modèle de **régression logistique pondéré** a été ajusté pour estimer l'effet marginal du traitement antibiotique sur la mortalité.

Effet marginal du traitement (IPTW)

OR = 0.782 [0.566; 1.077]



Traitement	Odds Ratio (OR)	Intervalle de Confiance (95 %)	p-valeur
Antibiotiques (A)	0.782	[0.566 ; 1.077]	0.134

7. Interprétation

- L'odds ratio de **0.782** suggère une **réduction de 21.8 % du risque de mortalité intrahospitalière** chez les patients ayant reçu des antibiotiques.
- Toutefois, l'intervalle de confiance [0.566 ; 1.077] inclut la valeur 1 et la **p-valeur de 0.134 n'est pas significative**, indiquant que cet effet **n'est pas statistiquement prouvé** dans cet échantillon.

8. Analyse pondérée avec Entropy Balancing

Cette technique ajuste les poids de manière à imposer un équilibrage exact des moments statistiques (notamment les moyennes) des covariables entre les groupes, sans modélisation du score de propension.

Toutefois, l'application directe de l'Entropy Balancing à l'ensemble des covariables disponibles a conduit à une erreur d'optimisation : l'algorithme ne parvenait pas à trouver une solution valide, en raison du nombre élevé de variables et de leur colinéarité potentielle. Ce phénomène est fréquent avec cette méthode, qui devient instable lorsque les contraintes sont trop nombreuses.

```
# 1. Estimation des poids via Entropy Balancing
> w.ebal <- weightit(A ~ ., data = df_ipw, method = "ebal", estimand = "ATE")
Avis : The estimated weights do not balance the covariates, indicating the
optimization arrived at a degenerate solution. Try decreasing the number of
variables supplied to the optimization.
Avis : All weights are `NA` or 0 in treatment group "1".
>
> # 2. Ajouter les poids au dataset
> df_ipw$poids_ebal <- get.w(w.ebal)
>
> # 3. Vérifier l'équilibre des covariables
> bal_ebal <- bal.tab(w.ebal, un = TRUE, m.threshold = 0.1)
Error in `bal.tab()`:
! All weights are zero when treat is "1".
Run `rlang::last_trace()` to see where the error occurred.
```

Pour contourner ce problème, nous avons sélectionné un **sous-ensemble de variables cliniquement pertinentes**, incluant notamment l'âge, le sexe, le score de gravité (Knaus, Glasgow), les marqueurs biologiques (CRP, leucocytes, créatinine, DFG), ainsi que le motif de consultation.

Ce choix permet de conserver un bon pouvoir d'ajustement tout en assurant la convergence de l'optimisation.

Résultats :

Après pondération :

- L'équilibre des covariables était parfaitement atteint (aucune SMD > 0.1),
- Le modèle de régression logistique pondéré donnait un odds ratio (OR) de 1.00 [0.61 ; 1.64], avec une p-valeur = 1.

```
> print(effet_ebal_A)
# A tibble: 1 × 4
  Variable      OR `IC 95%`      `p-value`
  <chr>      <dbl> <chr>      <dbl>
1 A (antibio)      1 [0.61 ; 1.64]      1
```

Interprétation : Le traitement antibiotique n'apparaît pas associé à une modification du risque de mortalité dans cette analyse.

Ces résultats confirment les tendances observées avec la méthode IPTW : **après ajustement**, l'effet apparent des antibiotiques observé dans l'analyse brute (non ajustée) disparaît.


9. Tableau comparatif

Afin d'estimer l'effet du traitement (antibiothérapie, variable A) sur l'issue binaire (Y), trois approches statistiques ont été comparées : une **Analyse brute**, pondération par l'**Inverse Probability of Treatment Weighting (IPTW)**. et l'**Ebalancing**. Les résultats sont synthétisés dans le tableau ci-dessous :

	Méthode	OR	IC 95%	p-value
1	Analyse brute	4.12	[2.39 ; 7.44]	< 0.001
2	IPTW	0.78	[0.57 ; 1.08]	0.134
3	Entropy Balancing	1.00	[0.61 ; 1.64]	1

1. **L'analyse brute** montre un **OR de 4,12**, suggérant une association forte et significative entre le traitement et l'issue. Cependant, cette approche ne tient pas compte des biais de confusion potentiels, ce qui peut entraîner une surestimation de l'effet.
2. **L' IPTW**, l'effet estimé devient non significatif (OR = 0,78 ; p = 0,134), ce qui suggère que les différences de caractéristiques entre les groupes traités et non traités expliquaient en grande partie l'effet observé initialement qui montrait un OR de 4,12 (p < 0,001), suggérant un risque de décès quatre fois plus élevé chez les patients traités par antibiotiques. Cependant, cet effet était vraisemblablement biaisé par des facteurs de confusion
3. **L'approche par entropy balancing** confirme cette tendance avec un **OR neutre de 1,00** (p = 1), indiquant **aucune différence significative** entre les groupes une fois l'équilibrage effectué.

Ces résultats illustrent bien **l'importance des méthodes d'ajustement** pour estimer correctement l'effet causal d'un traitement. L'analyse brute peut être trompeuse en présence de confusions, alors que les méthodes pondérées (IPTW et EB) permettent d'obtenir des estimations plus robustes et interprétables.



Ce graphique présente les Odds Ratios (OR) estimés et leurs intervalles de confiance (IC 95%) pour l'effet du traitement, obtenus par trois méthodes différentes : Analyse brute, IPTW et Entropy Balancing.

- **Analyse brute** : Montre un OR élevé (environ 4), indiquant un effet important du traitement. Cependant, l'intervalle de confiance est large, ce qui traduit une incertitude importante, et l'absence d'ajustement aux facteurs confondants peut biaiser ce résultat.
- **IPTW** : L'OR est proche de 1, avec un intervalle de confiance plus resserré autour de cette valeur. Cette méthode ajuste les différences entre groupes, réduisant ainsi le biais de confusion.
- **Entropy Balancing** : Confirme les résultats IPTW avec un OR proche de 1 et un intervalle de confiance large mais centré sur 1, indiquant qu'après équilibrage des covariables, le traitement n'a pas d'effet significatif.

La ligne verticale en pointillé à $OR=1$ représente le seuil de neutralité.

10. Conclusion

En résumé, nos analyses montrent que l'association initialement observée entre l'administration d'antibiotiques et la mortalité est largement atténuée après ajustement pour les facteurs de confusion. Les méthodes d'ajustement comme l'IPTW et l'Entropy Balancing sont essentielles pour estimer des effets causaux valides dans les études observationnelles.

Cependant, Cette étude présente certaines limites. D'une part, la qualité de l'ajustement dépend de l'exhaustivité des covariables mesurées. D'autre part, l'Entropy Balancing n'a pu être appliqué qu'à un sous-ensemble de variables, ce qui peut introduire un biais résiduel.

Ces résultats rappellent l'importance de ne pas interpréter directement les résultats non ajustés en pratique médicale. L'application de méthodes d'ajustement robustes devrait devenir un standard dans les analyses observationnelles.